網頁資料擷取

擷取網頁資料的前題是不能觸犯著作權:

- https://www.tipo.gov.tw/ct.asp?xltem=219598&ctNode=7561&mp=1 (https://www.tipo.gov.tw/ct.asp?xltem=219598&ctNode=7561&mp=1)
- https://udn.com/news/story/6871/3221682 (https://udn.com/news/story/6871/3221682)

這個單元例子僅用來說明由網頁擷取資料的入門技巧。

- 使用re
- 使用BeautifulSoup
- 使用Selenium

解析網址

單純網址

```
In [ ]:
```

```
1 # coding=utf-8
2 from urllib.parse import urlparse
3 url = 'https://tw.stock.yahoo.com/news_list/url/d/e/'
4 up = urlparse(url)
5 print(up)
```

In []:

```
1 # coding=utf-8
2 from urllib.parse import urlparse
3 url = 'https://www.cwb.gov.tw/V7/forecast/index.htm'
4 up = urlparse(url)
5 print(up)
```

有get參數

In []:

```
# coding=utf-8
from urllib.parse import urlparse
url = 'https://tw.stock.yahoo.com/q/q?s=2330'
up = urlparse(url)
print(up)
```

In []:

```
# coding=utf-8
from urllib.parse import urlparse
url = 'https://ecshweb.pchome.com.tw/search/v3.3/?q=pc&scope=all'
up = urlparse(url)
print(up.query.split('&'))
```

scheme: 通訊協定netloc: 網域名稱

• path: 網頁所在路徑與檔名

• query; GET參數

透過requests.get(url) 擷取網頁的內容

你可以從chrome瀏覽器找到各式user agent字串:按Ctrl-Shift-I啟動開發者工具,在Network選單,按右上選項圖示後選More tools>Network conditions。

在URL裡傳遞參數

In []:

```
import requests
keys = {'search_query': 'python'}
r=requests.get('https://www.youtube.com/results',params=keys)
print(r.url)
```

擷取網頁的內容

方式一: r.content (它是bytes型態)

可透過下面方式將bytes轉str

- 轉換方法一: r.content.decode('utf-8')
- 轉換方法二: str(r.content,encoding='utf-8')

str轉bytes

- 轉換方法一: s.encode('utf-8')
- 轉換方法二: bytes(s, encoding='utf-8')

In []:

```
import requests
url = 'https://www.cwb.gov.tw/V7/forecast/index.htm'
r = requests.get(url)
for i in r.content.decode('utf-8').splitlines()[:10]:
    print(i)
```

方式二: r.text (它是str型態)

如下面所示,requests編碼方式為ISO-8859-1。

In []:

```
import requests
url = 'https://www.cwb.gov.tw/V7/forecast/index.htm'
#html = requests.get(url).content.decode('utf-8','ignore').splitlines()
r = requests.get(url)
print(r.encoding)
```

用r.encoding='utf-8'將編碼改為'utf-8'編碼後,處理網頁內容。

In []:

```
import requests
url = 'https://www.cwb.gov.tw/V7/forecast/index.htm'
r = requests.get(url)
r.encoding = 'utf-8'
for i in r.text.splitlines()[:10]:
    print(i)
```

使用re模組擷取資訊

HTML網頁格式

HTML標記	用途說明	
<html></html>	標記為HTML文件	
<head></head>	標記為HTML文件標頭	
<title></title>	標記為HTML文件標題,通常會顯示在瀏覽器標題列	
<body></body>	標記為HTML文件內容	
<script></script>	標記為描述語言	
<h1></h1>	標記為標題(等級為h1,,h6)	
	標記為文字段落	
<div></div>	排版用格式標記,通常為內文大段落或顯示分塊	
	類似 <div>,通常用在小段落</div>	

HTML標記 用途說明

```
    ...
    標記...為表格呈現內容

    <img src='...'>
    顯示圖形檔設定

    <a href='...'>
    外部連結設定
```

例子:使用re擷取網頁裡的新聞標題

https://udn.com/news/cate/2/7226 (https://udn.com/news/cate/2/7226) 網頁裡新聞標題寫在<h2> ... </h2>段落,如下範例

```
 <h2 style="width:100%">專利戰高通告贏蘋果 陸將禁售iPhone X以前機種 <time>22:29</time
></h2>
  <h2>先從海外版施行 日本漫畫週刊少年Jump也走向數位訂閱制<span class="i-video1"></span>
</h2>
```

In []:

```
import requests
import re
import re
import re
import re
url = 'https://udn.com/news/cate/2/7226'
html = requests.get(url).content.decode('utf-8')
for idx,title in enumerate(re.finditer(r'<h2[^>]*?>([^<]*?)(<time.+?/time>)?(<span.+?/sprint('{:4d}. {}'.format(idx+1,title.group(1)))</pre>
```

使用BeautifulSoup模組擷取資訊

https://www.crummy.com/software/BeautifulSoup/bs4/doc/ (https://www.crummy.com/software/BeautifulSoup/bs4/doc/)

安裝

```
conda install -c anaconda beautifulsoup4
```

找到所有<h2> ... </h2>段落程式片段

```
from bs4 import BeautifulSoup
import requests
url = 'https://udn.com/news/cate/2/7226'
html = requests.get(url).content.decode('utf-8')
sp = BeautifulSoup(html,'html.parser')
for link in sp.find_all('h2'):
    print('{}'.format(link.text))
```

```
指令範例 說明
sp.find('a'[,key]) 傳回第一個符合的內容
sp.find_all('a'[,key]) 傳回所有符合的內容
sp.title/sp.title.text 傳回<title>網頁標題</title>
```

指令範例 說明

sp.text 傳回去掉HTML標籤的內容

例子:使用BeautifulSoup擷取網頁裡的新聞標題

In []:

```
from bs4 import BeautifulSoup
import requests
url = 'https://udn.com/news/cate/2/7226'
html = requests.get(url).content.decode('utf-8')
sp = BeautifulSoup(html,'html.parser')

for idx,link in enumerate(sp.find_all('h2')):
    print('{:4d}. {}'.format(idx+1,link.text))
```

例子: 擷取表格資料

中央氣象局月平均氣溫表格HTML原始碼:

https://www.cwb.gov.tw/V7/climate/monthlyMean/Taiwan_tx.htm (https://www.cwb.gov.tw/V7/climate/monthlyMean/Taiwan_tx.htm)

```
一月
二月
三月
四月
五月
六月
七月
八月
九月
十月
十一月
十二月
平均
統計期間
淡水
15.2
15.6
17.4
21.1
24.5
26.9
28.8
28.6
26.7
23.7
20.6
16.9
22.2
1981-2010
```

平均氣溫表格放在標記內。可是那個網頁有許多標記,不過其中class為Form00為平均氣溫表格。因此table = sp.find_all('table',{'class':'Form00'})可以鎖定以'class'為key, value為'Form00'的那個標記。

第一列,為標題列,每一欄以,標記標示。下面指令找出,標記內每一欄。

In []:

```
1 from bs4 import BeautifulSoup
2 import requests
3 import numpy as np
4 import matplotlib.pyplot as plt
6 url = 'https://www.cwb.gov.tw/V7/climate/monthlyMean/Taiwan_tx.htm'
7 html = requests.get(url).content.decode('utf-8')
8 sp = BeautifulSoup(html, 'html.parser')
9 table = sp.find('table',{'class':'Form00'})
10 rows = table.find_all('tr')
11
12 title = [c.text for c in rows[0].find_all('th')]
13 data = [list() for _ in range(len(title))]
14
15 for r in rows[1:]:
16
       for col,cell_data in zip(data,r.find_all('td')):
17
18
               col.append(float(cell_data.text))
19
           except ValueError:
20
               col.append(cell_data.text)
21
22 #放入 numpy.ndarray
23
24 data_table= np.core.records.fromarrays(data)
25 data_table.dtype.names = title
26
27 # 資料標題
28 print(data_table.dtype.names)
29
30 #取得第0列資料
31 print(data_table[0])
32
33 #取得各觀測站五月均溫
34 print(data_table['五月'])
35
```

```
In [ ]:
```

```
import matplotlib.pyplot as plt
from matplotlib.font_manager import FontProperties
import os

font = FontProperties(fname=os.environ['WINDIR']+'\\Fonts\\kaiu.ttf', size=12)

plt.figure(figsize=(8,4))
for i in range(5):
    r = list(data_table[i])
    plt.plot(np.arange(len(data_table.dtype.names)-3),r[1:-2],label=r[0])

plt.legend(prop=font)
plt.title('平均氣溫',fontproperties=font)
plt.xticks(np.arange(len(title)-3),title[1:-2],fontproperties=font)
plt.ylabel('攝氏',fontproperties=font)
plt.show()
```

例子: 擷取所有連結

HTML連結格式為:

```
<a href='https://tw.yahoo.com/?p=us'>本文</a>
```

所以

```
all_links = sp.find_all('a')
```

得到所有<a>....段落。假設link為以上連結為例子,

- link.get('href')得到'https://tw.yahoo.com/?p=us (https://tw.yahoo.com/?p=us)
- link.text得到'本文'

In []:

```
from bs4 import BeautifulSoup
import requests
url = 'https://udn.com/news/index'
html = requests.get(url).content.decode('utf-8')
sp = BeautifulSoup(html,'html.parser')

for idx,link in enumerate(sp.find_all('a')):
    href = link.get('href')
    if href is not None and href.startswith('http'):
        print('{:4d} text:{:<s}, link:{:>s}'.format(idx+1,link.text,href))
```

例子:擷取所有圖形檔

下面例子需要用到pillow模組

```
conda install -c anaconda pillow
```

```
In [ ]:
```

```
1 from bs4 import BeautifulSoup
 2 import requests
3 from urllib.parse import urlparse
4 from urllib.request import urlopen
 5 import matplotlib.pyplot as plt
 6 from PIL import Image, ImageDraw, ImageFont
7 import numpy as np
8 import io
9 import re
10
11 url = 'https://udn.com/news/story/7934/3526132'
12
13 headers = {'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; WOW64) AppleWebKit/537.36 (KHT
14
               'Content-Type': 'application/x-www-form-urlencoded',
           'Connection' : 'Keep-Alive',
15
16
           'Accept': 'text/html,application/xhtml+xml,application/xml;q=0.9,*/*;q=0.8',
           'Accept-Encoding': 'gzip, deflate, sdch',
17
           'Accept-Languate': 'en-US,en;q=0.8'}
18
19
20 uc = urlparse(url)
21 print(uc.scheme,uc.hostname)
22 domain = '{}://{}'.format(uc.scheme,uc.hostname)
23 print(domain)
24
25 html = requests.get(url,headers=headers).content.decode('utf-8')
26
27 sp = BeautifulSoup(html,'html.parser')
28 for idx,link in enumerate(sp.find_all(['a','img'])):
       href = link.get('href')
29
30
       src = link.get('src')
31
       for t in [href, src]:
           if t is not None and ('.jpg' in t or '.png' in t):
32
33
               if t.startswith('http'):
34
                   img path = t
35
               elif t.startswith('//'):
36
                   img_path = 'https:'+t
37
               else:
38
                   domain+t
39
               print(img_path)
               print('filename:{}'.format(re.search('[^/]+((.jpg)|(.png))',img_path).group
40
41
               image = urlopen(img path)
42
               img = Image.open(image)
43
               plt.imshow(img)
44
               plt.axis('off')
45
               plt.show()
46
```

透過Selenium擷取網頁資料

安裝

```
conda install -c conda-forge selenium
```

安裝各瀏覽器的webdriver載點<u>https://www.seleniumhq.org/about/platforms.jsp</u>(https://www.seleniumhq.org/about/platforms.jsp)

如Chrome web driver: https://sites.google.com/a/chromium.org/chromedriver/home)

並將webdriver(如chromedriver.exe)放在Python執行的目錄內。測試下面範例:

操作瀏覽器函式

```
webdriver方法
                                 說明
           refresh() 重新整理頁面
             back() 回上一頁
           forward() 到下一頁
            close() 關視窗
              quit() 結束瀏覽器
            get(url) 瀏覽url這網址
          current_url 目前網址
               title 網頁標題
        page_source 網頁原始碼
save_screenshot(pngfile) 存目前網頁畫面於png檔
 get_window_position() 取得視窗左上角位置
set_window_position(x,y) 設定視窗左上角位置
   maximize_window() 最大化視窗
    get_window_size() 取得視窗大小
  set_window_size(x,y) 設定視窗大小
```

In []:

```
from selenium import webdriver
urls = ['https://www.cwb.gov.tw/V7/','https://tw.yahoo.com/?p=us']
web = webdriver.Chrome()
for idx,url in enumerate(urls):
    web.get(url)
    web.save_screenshot('screenshot_{}.png'.format(idx))
web.quit()
```

In []:

```
import matplotlib.pyplot as plt
import matplotlib.image as mpimg
fig = plt.figure(figsize=(15,30))
for idx in range(len(urls)):
    img = mpimg.imread('screenshot_{{}}.png'.format(idx))
    plt.subplot(1,2,idx+1)
    plt.imshow(img)
    plt.axis('off')
plt.show()
```

網頁元素檢索功能

web = webdriver.Chrome()
web.get(url)

- # 檢索網頁元素,通常元素id為唯一,比較好找 element = web.find_element_by_id(id)
- # 操作網頁元素

element.send_keys(value) element.submit() # 提交

webdriver元素檢索方法

說明

find_element_by_X(value)	使用X檢索,取得第一個符合的元素
find_element_by_class_name(name)	使用類別名稱檢索
find element by css selector(selector)	使用CSS選擇器檢索
mia_didment_by_ddd_ddiddiddiddiddiddid	次/11000/2017 品
find_element_by_id(id)	使用id檢索
find_element_by_link_text(text)	使用連結文字檢索
find_element_by_name(name)	使用名稱檢索
find_element_by_tag_name(name)	使用HTML標籤檢索

webdriver元素操作方法

說明

clear() 清除內容

click() 點擊,通常用於按鈕、連結、選單

find_elements_by_X 使用X檢索,取得所有符合的元素

send_keys(value) 對此元素送出字串

submit() 提交

is_displayed() 此元素是否可見

is_enabled() 此元素是否可用

is_selected() 此元素是否被選定

```
In [ ]:
```

```
from selenium import webdriver

web = webdriver.Chrome()
web.maximize_window()
web.get("https://www.google.com")

#找到輸入框
element = web.find_element_by_name("q")

#輸入
element.send_keys("中央氣象局")

#提交
element.submit()

#web.close()
```

In []:

```
1 from selenium import webdriver
2 import time
3
4 web = webdriver.Chrome()
 5 web.maximize_window()
6 web.get("https://www.youtube.com")
7
8 #找到輸入框
9 element = web.find_element_by_id("search")
10
11 #輸入
12 element.send_keys("selenium Python")
13
14 #按搜尋
15 search_btn = web.find_element_by_id("search-icon-legacy")
16 search_btn.click()
17 # Get scroll height
18 last_height = -1
19 for idx in range(500):
20
       # Scroll down to bottom
21
       web.execute_script("window.scrollTo(0, window.scrollY + 800);")
22
       # Wait to Load page
23
       time.sleep(.5)
24
       current_height = web.execute_script("return window.scrolly")
25
       if last_height == current_height:
26
           print('stop')
27
           break
28
       last_height = current_height
29
```

In []:

```
1 print(web.page_source.splitlines()[:5])
```

```
In [ ]:
```

```
1
```